



# 概率论与数理统计

相关结论及其证明

AUTHOR LiH

CONTACT [lihow@stu.xmu.edu.cn](mailto:lihow@stu.xmu.edu.cn)



# 前言

参考教材:《概率论与数理统计(第五版)》

ISBN: 9787040516609

只从考试的角度来看,概统只需要掌握结论并应用即可,但是这样在做一些涉及到原理的题目可能会比较吃亏。因此,本 pdf 主要对相关结论(第一章的内容和高中的知识联系较紧密,这里不再讨论)给出较为详细的证明,内容可能比较啰嗦且涉及到课本之外的理论,已经掌握原理或只想记结论的同学请跳着阅读,以减轻负担。同时由于时间比较赶,证明过程中可能有笔误或其他错误,如果阅读中有觉得不对的地方,请联系封面邮箱改正。

另外,概统后面可能会用到各种概率分布函数,如果有同学不想查表的话,可以载 geogebra, 选择概率计算器。

官网: <https://www.geogebra.org/>

国内镜像: <https://ggb123.cn/>



# 目录

|                             |           |
|-----------------------------|-----------|
| <b>1 主要结论及证明</b>            | <b>1</b>  |
| 1.1 各种分布以及相关结论 . . . . .    | 1         |
| 1.2 随机变量(一维、二维)相关 . . . . . | 6         |
| 1.3 第四章相关 . . . . .         | 10        |
| <b>2 例题</b>                 | <b>14</b> |
| 2.1 各种分布的可加性 . . . . .      | 14        |
| 2.2 随机变量的函数的分布 . . . . .    | 17        |
| 2.3 边缘分布和条件分布 . . . . .     | 21        |
| 2.4 最大值、最小值分布 . . . . .     | 23        |



# 1 主要结论及证明

## 1.1 各种分布以及相关结论

### 1. 0-1 分布与二项分布

0-1 分布(特殊的二项分布)

- 期望:  $E(X) = p$
- 方差:  $D(X) = p(1 - p)$

二项分布  $X \sim b(n, p)$  或  $X \sim B(n, p)$

- 分布律:  $P(X = k) = C_n^k p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n$
- 期望:  $E(X) = np$
- 方差:  $D(X) = np(1 - p)$

证明提示 将  $X$  看成  $n$  个独立同分布的 0-1 分布变量  $X_i$  的和, 即  $X = \sum_{i=1}^n X_i$ 。由于期望和方差(独立前提下)具有可加性, 因此  $E(X) = \sum E(X_i) = np$ , 且  $D(X) = \sum D(X_i) = np(1 - p)$ 。

## 2. 泊松分布

### 引理 1.1 指数函数的麦克劳林展开

对于任意实数  $\lambda$ , 指数函数  $e^\lambda$  可以展开为幂级数, 这是推导泊松分布数字特征的核心基础:

$$e^\lambda = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = 1 + \lambda + \frac{\lambda^2}{2!} + \dots$$

$X \sim \pi(\lambda)$  或  $X \sim P(\lambda)$

- 分布律:  $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$ ,  $k = 0, 1, 2, \dots$
- 泊松定理(二项分布的极限): 当  $n \geq 20, p \leq 0.05$  时, 有近似公式  $C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$ , 其中  $\lambda = np$ 。

期望与方差的证明

首先求期望  $E(X)$ :

$$E(X) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k(k-1)!} = e^{-\lambda} \cdot \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = e^{-\lambda} \cdot \lambda \cdot e^\lambda = \lambda$$

接着求  $E(X^2)$ , 这里的核心技巧是利用  $k^2 = k(k-1) + k$  进行拆项:

$$\begin{aligned} E(X^2) &= \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} (k(k-1) + k) \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=2}^{\infty} k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} + \sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + E(X) \\ &= \lambda^2 e^{-\lambda} \cdot e^\lambda + \lambda = \lambda^2 + \lambda \end{aligned}$$

最后计算方差:

$$D(X) = E(X^2) - [E(X)]^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda$$

### 3. 几何分布与超几何分布

#### 引理 1.2 幂级数逐项求导

对于无穷等比级数  $\sum_{k=1}^{\infty} q^k = \frac{q}{1-q}$  (其中  $|q| < 1$ ), 在收敛域内可以逐项求导。即:

$$\sum_{k=1}^{\infty} kq^{k-1} = \frac{1}{(1-q)^2}$$

同理, 对上式再次求导可得:

$$\sum_{k=2}^{\infty} k(k-1)q^{k-2} = \frac{2}{(1-q)^3}$$

几何分布

- 分布律:  $P(X = k) = (1-p)^{k-1}p, \quad k = 1, 2, 3, \dots$
- 期望与方差:  $E(X) = \frac{1}{p}, \quad D(X) = \frac{1-p}{p^2}$

期望与方差的证明

令  $q = 1 - p$ 。利用上述引理, 直接代入可得期望:

$$E(X) = \sum_{k=1}^{\infty} k \cdot q^{k-1}p = p \sum_{k=1}^{\infty} kq^{k-1} = p \cdot \frac{1}{(1-q)^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}$$

求方差时, 先求  $E[X(X-1)]$ :

$$E[X(X-1)] = \sum_{k=1}^{\infty} k(k-1)q^{k-1}p = pq \sum_{k=2}^{\infty} k(k-1)q^{k-2} = pq \cdot \frac{2}{(1-q)^3} = pq \cdot \frac{2}{p^3} = \frac{2q}{p^2}$$

$$D(X) = E[X(X-1)] + E(X) - [E(X)]^2 = \frac{2(1-p)}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

#### 引理 1.3 组合数恒等式

在组合数学中, 有以下两个常用于概率论推导的重要恒等式:

- 吸收恒等式:  $kC_M^k = MC_{M-1}^{k-1}$ , 同理  $k(k-1)C_M^k = M(M-1)C_{M-2}^{k-2}$ 。
- 范德蒙德卷积公式:  $\sum_k C_A^k C_B^{n-k} = C_{A+B}^n$ 。

超几何分布 场景:  $N$  件物品, 其中  $M$  件次品, 不放回地抽取  $n$  件。  $X$  表示抽到的次品数。

- 分布律:  $P(X = k) = \frac{C_M^k \cdot C_{N-M}^{n-k}}{C_N^n}$ ,  $k = 0, 1, 2, \dots, \min\{n, M\}$
- 期望:  $E(X) = np$ , 其中  $p = \frac{M}{N}$  为次品率。
- 方差:  $D(X) = np(1-p)\frac{N-n}{N-1}$ , 其中  $p = \frac{M}{N}$  为次品率。

期望与方差的证明

证明的核心在于利用引理中的吸收恒等式以及范德蒙德卷积公式。

$$\begin{aligned} E(X) &= \sum_{k=1}^n k \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \sum_{k=1}^n \frac{M C_{M-1}^{k-1} C_{N-M}^{n-k}}{\frac{N}{n} C_{N-1}^{n-1}} \\ &= n \frac{M}{N} \sum_{k=1}^n \frac{C_{M-1}^{k-1} C_{(N-1)-(M-1)}^{(n-1)-(k-1)}}{C_{N-1}^{n-1}} \end{aligned}$$

由于后半部分的求和代表了在  $N-1$  件物品中抽取  $n-1$  件的所有概率之和, 其值等于 1。因此:

$$E(X) = n \frac{M}{N} = np$$

求方差同样先求  $E[X(X-1)]$ :

$$\begin{aligned} E[X(X-1)] &= \sum_{k=2}^n k(k-1) \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \sum_{k=2}^n \frac{M(M-1) C_{M-2}^{k-2} C_{N-M}^{n-k}}{\frac{N(N-1)}{n(n-1)} C_{N-2}^{n-2}} \\ &= \frac{n(n-1)M(M-1)}{N(N-1)} \sum_{k=2}^n \frac{C_{M-2}^{k-2} C_{(N-2)-(M-2)}^{(n-2)-(k-2)}}{C_{N-2}^{n-2}} \\ &= \frac{n(n-1)M(M-1)}{N(N-1)} \end{aligned}$$

最后代入方差公式化简(令  $p = \frac{M}{N}$ ):

$$\begin{aligned} D(X) &= E[X(X-1)] + E(X) - [E(X)]^2 \\ &= \frac{n(n-1)M(M-1)}{N(N-1)} + np - n^2 p^2 \\ &= np \left[ \frac{(n-1)(M-1)}{N-1} + 1 - np \right] \\ &= np(1-p) \frac{N-n}{N-1} \end{aligned}$$



## 4. 指数分布

### 引理 1.4 分部积分法

在计算连续型随机变量(如指数分布、正态分布)的数字特征时,常利用分部积分法消去被积函数中的多项式因子:

$$\int u dv = uv - \int v du$$

$$X \sim E(\lambda)$$

也有参数化形式为  $\theta = \frac{1}{\lambda}$ , 请根据任课老师要求记忆:

- 概率密度函数:  $f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其他} \end{cases}$
- 分布函数:  $F(x) = \begin{cases} 1 - e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其他} \end{cases}$

无记忆性证明, 即证明  $P\{X > s+t \mid X > s\} = P\{X > t\}$ :

$$\begin{aligned} P\{X > s+t \mid X > s\} &= \frac{P\{X > s+t \text{ 且 } X > s\}}{P\{X > s\}} = \frac{P\{X > s+t\}}{P\{X > s\}} \\ &= \frac{1 - F(s+t)}{1 - F(s)} = \frac{e^{-\frac{s+t}{\theta}}}{e^{-\frac{s}{\theta}}} = e^{-\frac{t}{\theta}} \\ &= 1 - F(t) = P\{X > t\} \end{aligned}$$

期望与方差的证明(利用分部积分法)

$$\begin{aligned} E(X) &= \int_0^{+\infty} x \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = - \int_0^{+\infty} x d(e^{-\frac{x}{\theta}}) \\ &= - [xe^{-\frac{x}{\theta}}]_0^{+\infty} + \int_0^{+\infty} e^{-\frac{x}{\theta}} dx \\ &= 0 + [-\theta e^{-\frac{x}{\theta}}]_0^{+\infty} = \theta \end{aligned}$$

同理, 两次运用分部积分法求  $E(X^2)$ :

$$\begin{aligned} E(X^2) &= \int_0^{+\infty} x^2 \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = 2\theta^2 \\ D(X) &= E(X^2) - [E(X)]^2 = 2\theta^2 - \theta^2 = \theta^2 \end{aligned}$$



## 5. 均匀分布

$$X \sim U(a, b)$$

- 概率密度函数:  $f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$

期望与方差的证明

$$E(X) = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \left[ \frac{1}{2} x^2 \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}$$

求方差先求  $E(X^2)$ :

$$E(X^2) = \int_a^b x^2 \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \left[ \frac{1}{3} x^3 \right]_a^b = \frac{b^3 - a^3}{3(b-a)} = \frac{1}{3}(a^2 + ab + b^2)$$

$$\begin{aligned} D(X) &= E(X^2) - [E(X)]^2 = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} \\ &= \frac{4a^2 + 4ab + 4b^2 - 3(a^2 + 2ab + b^2)}{12} \\ &= \frac{a^2 - 2ab + b^2}{12} = \frac{1}{12}(b-a)^2 \end{aligned}$$

## 6. 正态分布

$$X \sim N(\mu, \sigma^2)$$

- 概率密度函数:  $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
- 期望与方差:  $E(X) = \mu, \quad D(X) = \sigma^2$

重要性质

- 标准正态分布对称性: 若  $X \sim N(0, 1)$ , 则  $\Phi(x) + \Phi(-x) = 1$ 。
- 标准化变换: 若  $X \sim N(\mu, \sigma^2)$ , 则  $\frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

## 1.2 随机变量（一维、二维）相关

### 1. 一维随机变量的函数的分布

## 引理 1.5 复合函数与变上限积分求导法则

在推导随机变量函数的概率密度时,通常先求分布函数  $F_Y(y)$ ,再对其求导。对于形如  $F(y) = \int_{a(y)}^{b(y)} f(t)dt$  的积分,其导数为:

$$F'(y) = f(b(y)) \cdot b'(y) - f(a(y)) \cdot a'(y)$$

**经典例题:平方的分布** 设连续型随机变量  $X$  的概率密度为  $f_X(x)$ ,求  $Y = X^2$  的概率密度  $f_Y(y)$ 。

**详细推导** 首先求  $Y$  的分布函数  $F_Y(y)$ 。显然,当  $y < 0$  时,  $P\{X^2 \leq y\} = 0$ 。  
当  $y \geq 0$  时:

$$F_Y(y) = P\{Y \leq y\} = P\{X^2 \leq y\} = P\{-\sqrt{y} \leq X \leq \sqrt{y}\}$$

利用分布函数的定义,上式可以写为:

$$F_Y(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

对  $y$  求导,利用复合函数求导法则,可得  $Y$  的概率密度函数:

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} [F_X(\sqrt{y}) - F_X(-\sqrt{y})] \\ &= f_X(\sqrt{y}) \cdot \left(\frac{1}{2\sqrt{y}}\right) - f_X(-\sqrt{y}) \cdot \left(-\frac{1}{2\sqrt{y}}\right) \\ &= \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] \end{aligned}$$

## 2. 二维随机变量

### 引理 1.6 分布函数与概率密度的微积分关系

对于二维连续型随机变量  $(X, Y)$ ,其联合分布函数  $F(x, y)$  与联合概率密度  $f(x, y)$  满足:

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du \quad \text{且} \quad \frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$$

**边缘分布 (Marginal Distribution)** 将联合分布中的另一个变量“积分掉”,即可得到边缘分布。

• 分布函数:

$$F_X(x) = \lim_{y \rightarrow +\infty} F(x, y) = \int_{-\infty}^x \left[ \int_{-\infty}^{+\infty} f(t, y) dy \right] dt$$

- 概率密度函数及其推导: 对  $F_X(x)$  两边关于  $x$  求导, 由微积分基本定理可得:

$$f_X(x) = \frac{d}{dx} \int_{-\infty}^x \left( \int_{-\infty}^{+\infty} f(t, y) dy \right) dt = \int_{-\infty}^{+\infty} f(x, y) dy$$

同理可证  $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$ 。

### 条件分布 (Conditional Distribution)

- 离散型:  $P\{X = x_i | Y = y_j\} = \frac{P\{X=x_i, Y=y_j\}}{P\{Y=y_j\}}$
- 连续型概率密度及其推导: 考虑在  $y < Y \leq y + \Delta y$  的条件下,  $X \leq x$  的概率。当  $\Delta y \rightarrow 0$  时, 利用极限和积分中值定理:

$$\begin{aligned} F_{X|Y}(x|y) &= \lim_{\Delta y \rightarrow 0} P\{X \leq x | y < Y \leq y + \Delta y\} \\ &= \lim_{\Delta y \rightarrow 0} \frac{P\{X \leq x, y < Y \leq y + \Delta y\}}{P\{y < Y \leq y + \Delta y\}} \\ &= \lim_{\Delta y \rightarrow 0} \frac{\int_{-\infty}^x \int_y^{y+\Delta y} f(u, v) dv du}{\int_y^{y+\Delta y} f_Y(v) dv} \approx \frac{\int_{-\infty}^x f(u, y) \Delta y du}{f_Y(y) \Delta y} = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du \end{aligned}$$

两边对  $x$  求导, 即得条件概率密度:

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} \quad (f_Y(y) > 0)$$

独立性 (Independence) 若  $X$  和  $Y$  相互独立, 则联合分布等于边缘分布的乘积:

- 离散型:  $\forall x, y, \quad P\{X = x_i, Y = y_j\} = P\{X = x_i\} \cdot P\{Y = y_j\}$
- 任意型(分布函数):  $F(x, y) = F_X(x) \cdot F_Y(y)$
- 连续型(概率密度):  $f(x, y) = f_X(x) \cdot f_Y(y)$

## 3. 两个随机变量的函数的分布

### 引理 1.7 二维随机变量变换的雅可比行列式法

设  $(X, Y)$  的联合概率密度为  $f(x, y)$ 。作变换  $U = X, Z = g(X, Y)$ , 若其存在唯一反函数  $x = u, y = h(u, z)$ , 且偏导数连续, 则雅可比行列式(Jacobian)为:

$$J = \frac{\partial(x, y)}{\partial(u, z)} = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial z} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial z} \end{vmatrix} = \begin{vmatrix} 1 & 0 \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial z} \end{vmatrix} = \frac{\partial y}{\partial z}$$

变换后的联合概率密度为  $f_{U,Z}(u, z) = f(u, h(u, z)) \cdot |J|$ 。求  $Z$  的边缘密度只需对

$u$  (即  $x$ ) 积分:

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, h(x, z)) \left| \frac{\partial y}{\partial z} \right| dx$$

(1) 和的分布  $Z = X + Y$

- 一般情况与证明: 由  $z = x + y$  可得反函数  $y = z - x$ 。此时雅可比行列式  $J = \frac{\partial y}{\partial z} = 1$ 。代入引理公式直接得到:

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, z - x) \cdot |1| dx = \int_{-\infty}^{+\infty} f(x, z - x) dx$$

若  $X, Y$  相互独立, 则  $f(x, y) = f_X(x)f_Y(y)$ , 可得卷积公式:

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) \cdot f_Y(z - x) dx = \int_{-\infty}^{+\infty} f_X(z - y) \cdot f_Y(y) dy$$

- 正态分布的可加性: 若  $X \sim N(\mu_1, \sigma_1^2)$ ,  $Y \sim N(\mu_2, \sigma_2^2)$  且相互独立, 代入卷积公式并通过配方化简, 可证:

$$Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

(2) 商与积的分布

- 商  $Z = \frac{Y}{X}$ : 反函数为  $y = xz$ 。雅可比行列式  $J = \frac{\partial y}{\partial z} = x$ 。代入引理公式可证:

$$f_{Y/X}(z) = \int_{-\infty}^{+\infty} f(x, xz) \cdot |x| dx$$

- 积  $Z = XY$ : 反函数为  $y = \frac{z}{x}$ 。雅可比行列式  $J = \frac{\partial y}{\partial z} = \frac{1}{x}$ 。代入引理公式可证:

$$f_{XY}(z) = \int_{-\infty}^{+\infty} f\left(x, \frac{z}{x}\right) \cdot \left|\frac{1}{x}\right| dx$$

(3) 最大值与最小值的分布 (重难点)

假设  $X$  和  $Y$  相互独立, 其分布函数分别为  $F_X(x)$  和  $F_Y(y)$ 。

- 最大值分布  $M = \max\{X, Y\}$

推导:  $M \leq z$  意味着  $X$  和  $Y$  同时必须小于等于  $z$ 。由独立性可得:

$$\begin{aligned} F_{\max}(z) &= P\{M \leq z\} = P\{\max\{X, Y\} \leq z\} \\ &= P\{X \leq z \text{ 且 } Y \leq z\} \\ &= P\{X \leq z\} \cdot P\{Y \leq z\} = F_X(z) \cdot F_Y(z) \end{aligned}$$



- 最小值分布  $N = \min\{X, Y\}$

推导: 直接求  $\min \leq z$  比较困难, 我们转化为对立事件, 即  $\min > z$  意味着  $X$  和  $Y$  同时必须大于  $z$ 。

$$\begin{aligned} F_{\min}(z) &= P\{N \leq z\} = 1 - P\{N > z\} \\ &= 1 - P\{\min\{X, Y\} > z\} \\ &= 1 - P\{X > z \text{ 且 } Y > z\} \\ &= 1 - [P\{X > z\} \cdot P\{Y > z\}] \\ &= 1 - [(1 - F_X(z)) \cdot (1 - F_Y(z))] \end{aligned}$$

## 1.3 第四章相关

### 1. 切比雪夫不等式 (Chebyshev's Inequality)

#### 引理 1.8 切比雪夫不等式的意义

切比雪夫不等式给出了在随机变量分布未知的情况下, 仅仅利用其期望和方差, 就能估算出随机变量偏离其期望值的概率上限。

设随机变量  $X$  的数学期望为  $E(X) = \mu$ , 方差为  $D(X) = \sigma^2$ , 则对于任意给定的正数  $\varepsilon > 0$ , 有:

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$

等价形式(对立事件):

$$P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

证明 (以连续型随机变量为例, 离散型同理可证)

设  $X$  的概率密度函数为  $f(x)$ , 根据方差的定义:

$$D(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

由于被积函数非负, 我们可以缩小积分区间, 去掉  $|x - \mu| < \varepsilon$  的部分, 不等号依然成立:

$$D(X) \geq \int_{|x-\mu| \geq \varepsilon} (x - \mu)^2 f(x) dx$$

在积分区间  $|x - \mu| \geq \varepsilon$  上, 显然有  $(x - \mu)^2 \geq \varepsilon^2$ , 因此:

$$\begin{aligned} D(X) &\geq \int_{|x-\mu| \geq \varepsilon} \varepsilon^2 f(x) dx \\ &= \varepsilon^2 \int_{|x-\mu| \geq \varepsilon} f(x) dx \\ &= \varepsilon^2 P\{|X - \mu| \geq \varepsilon\} \end{aligned}$$

两边同除以  $\varepsilon^2$ , 即证得:

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}$$

## 2. 协方差与相关系数

协方差 (Covariance) 的定义与计算公式:

$$\text{Cov}(X, Y) = E[X - E(X)][Y - E(Y)]$$

计算公式推导:

$$\begin{aligned}\text{Cov}(X, Y) &= E[XY - X \cdot E(Y) - Y \cdot E(X) + E(X)E(Y)] \\ &= E(XY) - E(X)E(Y) - E(Y)E(X) + E(X)E(Y) \\ &= E(XY) - E(X)E(Y)\end{aligned}$$

相关系数 (Correlation Coefficient) 的定义:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

方差的展开公式:

$$D(X + Y) = D(X) + D(Y) + 2\text{Cov}(X, Y)$$

证明:

$$\begin{aligned}D(X + Y) &= E\{[(X + Y) - E(X + Y)]^2\} \\ &= E\{[(X - E(X)) + (Y - E(Y))]^2\} \\ &= E\{[X - E(X)]^2 + [Y - E(Y)]^2 + 2[X - E(X)][Y - E(Y)]\} \\ &= D(X) + D(Y) + 2\text{Cov}(X, Y)\end{aligned}$$

协方差的性质及证明:

- 提取常数:  $\text{Cov}(aX, bY) = ab \cdot \text{Cov}(X, Y)$

$$\text{证明: } \text{Cov}(aX, bY) = E[(aX - E(aX))(bY - E(bY))] = E[ab(X - E(X))(Y - E(Y))] = ab\text{Cov}(X, Y)$$

- 分配律:  $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$

不相关与独立的等价关系:

$$\rho_{XY} = 0 \iff X, Y \text{ 不相关} \iff \text{Cov}(X, Y) = 0 \iff E(XY) = E(X) \cdot E(Y)$$

### 引理 1.9 正态分布的特殊性

对于一般的随机变量, 独立必定不相关, 但不相关不一定独立。然而, 对于二维正态分布, 这两个概念是完全等价的。

当  $(X, Y)$  服从二维正态分布时:

$$X, Y \text{ 相互独立} \iff X, Y \text{ 不相关 (即 } \rho = 0 \text{)}$$

证明简述 若  $X, Y$  不相关, 即  $\rho = 0$ , 代入二维正态分布的概率密度展开式中:

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp \left\{ -\frac{1}{2} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\} \\ &= \left[ \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left( -\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right) \right] \cdot \left[ \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left( -\frac{(x_2 - \mu_2)^2}{2\sigma_2^2} \right) \right] \\ &= f_{X_1}(x_1) \cdot f_{X_2}(x_2) \end{aligned}$$

联合概率密度等于边缘概率密度的乘积, 故  $X, Y$  相互独立。反之, 若独立, 协方差必为 0, 即  $\rho = 0$ 。

## 3. 矩与协方差矩阵

矩 (Moments) 的定义

- $k$  阶原点矩:  $E(X^k)$
- $k$  阶中心矩:  $E\{[X - E(X)]^k\}$
- $k + l$  阶混合矩:  $E(X^k Y^l)$
- $k + l$  阶混合中心矩:  $E\{[X - E(X)]^k \cdot [Y - E(Y)]^l\}$

二维正态分布与协方差矩阵设  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则其相关系数  $\rho_{XY} = \rho$  其协方差矩阵  $C$  (或记为  $\Sigma$ ) 定义为:

$$C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$


二维正态分布的概率密度函数有两种表示方法:

(1) 矩阵形式 (更具一般性, 易于向高维推广): 记均值向量  $\boldsymbol{\mu} = (\mu_1, \mu_2)^T$ , 随机向量  $\mathbf{X} = (x_1, x_2)^T$ , 则:

$$f(x_1, x_2) = \frac{1}{(2\pi) \cdot |C|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T C^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

(2) 展开形式 (常用于代数计算):

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\}$$



## 2 例题

### 2.1 各种分布的可加性

#### 1. 常见分布的可加性总结

可加性(再生性)定义: 若随机变量  $X$  和  $Y$  相互独立, 且服从同一类型的分布(参数可以不同), 如果它们的和  $Z = X + Y$  仍然服从该类型的分布, 则称该分布具有可加性。

| 分布类型 | 是否可加 | 前提条件 (相互独立)         | 结论                                                                                        |
|------|------|---------------------|-------------------------------------------------------------------------------------------|
| 二项分布 | 是    | 成功率 $p$ 必须相同        | $B(n_1, p) + B(n_2, p) = B(n_1 + n_2, p)$                                                 |
| 泊松分布 | 是    | 无特殊限制               | $P(\lambda_1) + P(\lambda_2) = P(\lambda_1 + \lambda_2)$                                  |
| 正态分布 | 是    | 无特殊限制               | $N(\mu_1, \sigma_1^2) + N(\mu_2, \sigma_2^2) = N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ |
| 几何分布 | 否    | 即使 $p$ 相同也不可加       | 和服从负二项分布 (巴斯卡分布)                                                                          |
| 指数分布 | 否    | 即使 $\lambda$ 相同也不可加 | 和服从 Erlang 分布 (伽马分布特例)                                                                    |
| 均匀分布 | 否    | 即使区间相同也不可加          | 和服从分段函数 (如辛钦分布)                                                                           |



## 2. 经典例题与证明

### 例题 2.1 泊松分布的可加性证明

已知  $X \sim P(\lambda_1), Y \sim P(\lambda_2)$ , 且  $X$  与  $Y$  相互独立。证明  $Z = X + Y \sim P(\lambda_1 + \lambda_2)$ 。

解答 利用离散型随机变量和的分布公式(离散卷积):

$$P(Z = n) = P(X + Y = n) = \sum_{k=0}^n P(X = k)P(Y = n - k)$$

代入泊松分布的概率质量函数:

$$\begin{aligned} P(Z = n) &= \sum_{k=0}^n \frac{\lambda_1^k}{k!} e^{-\lambda_1} \cdot \frac{\lambda_2^{n-k}}{(n-k)!} e^{-\lambda_2} \\ &= e^{-(\lambda_1 + \lambda_2)} \sum_{k=0}^n \frac{1}{k!(n-k)!} \lambda_1^k \lambda_2^{n-k} \end{aligned}$$

为了凑出二项式展开, 我们在求和号内外同乘除  $n!$ :

$$\begin{aligned} P(Z = n) &= e^{-(\lambda_1 + \lambda_2)} \frac{1}{n!} \sum_{k=0}^n \frac{n!}{k!(n-k)!} \lambda_1^k \lambda_2^{n-k} \\ &= e^{-(\lambda_1 + \lambda_2)} \frac{1}{n!} \sum_{k=0}^n C_n^k \lambda_1^k \lambda_2^{n-k} \end{aligned}$$

利用二项式定理  $(a + b)^n = \sum_{k=0}^n C_n^k a^k b^{n-k}$ , 上式可化简为:

$$P(Z = n) = \frac{(\lambda_1 + \lambda_2)^n}{n!} e^{-(\lambda_1 + \lambda_2)}$$

这正是参数为  $\lambda_1 + \lambda_2$  的泊松分布的分布律, 得证。

### 例题 2.2 二项分布可加性的条件探究

已知  $X \sim B(n_1, p), Y \sim B(n_2, p)$ , 且  $X, Y$  相互独立。证明  $Z = X + Y \sim B(n_1 + n_2, p)$ 。如果两者的  $p$  不同, 还具有可加性吗?

解答 第一部分: 证明可加性 ( $p$  相同)

物理意义法(推荐):  $X$  表示在  $n_1$  次独立重复试验中成功的次数,  $Y$  表示在额外的  $n_2$  次独立重复试验中成功的次数, 每次成功率均为  $p$ 。那么  $X + Y$  显然表示在总共  $n_1 + n_2$  次独立重复试验中成功的总次数, 这严格符合二项分布的定义, 即  $Z \sim B(n_1 + n_2, p)$ 。

代数法(离散卷积):

$$\begin{aligned}
 P(Z = k) &= \sum_{i=0}^k P(X = i)P(Y = k - i) \\
 &= \sum_{i=0}^k [C_{n_1}^i p^i (1-p)^{n_1-i}] \cdot [C_{n_2}^{k-i} p^{k-i} (1-p)^{n_2-(k-i)}] \\
 &= p^k (1-p)^{n_1+n_2-k} \sum_{i=0}^k C_{n_1}^i C_{n_2}^{k-i}
 \end{aligned}$$

根据范德蒙德卷积公式  $\sum_{i=0}^k C_{n_1}^i C_{n_2}^{k-i} = C_{n_1+n_2}^k$ , 代入即得  $B(n_1 + n_2, p)$  的分布律。

第二部分:  $p$  不同时不可加的反例

若  $X \sim B(1, p_1)$ ,  $Y \sim B(1, p_2)$ ,  $p_1 \neq p_2$ 。  $Z = X + Y$  可能取值为  $0, 1, 2$ 。

$$P(Z = 2) = P(X = 1)P(Y = 1) = p_1 p_2$$

如果  $Z$  仍然服从二项分布, 设为  $B(2, p_3)$ , 则必有  $P(Z = 2) = p_3^2$ 。这意味着  $p_3 = \sqrt{p_1 p_2}$ 。但同时  $E(Z) = E(X) + E(Y) = p_1 + p_2$ 。如果  $Z \sim B(2, p_3)$ , 其期望应为  $2p_3 = 2\sqrt{p_1 p_2}$ 。显然  $p_1 + p_2 \neq 2\sqrt{p_1 p_2}$  (除非  $p_1 = p_2$ ), 产生矛盾。故  $p$  不同时不可加。

### 例题 2.3 几何分布与指数分布不可加的反例

分别计算两个独立同分布的几何分布之和、以及两个独立同分布的指数分布之和, 说明它们为何不具有可加性。

解答 (1) 几何分布的反例:

设  $X, Y \sim Ge(p)$  独立, 其分布律为  $P(X = k) = (1-p)^{k-1}p$  ( $k \geq 1$ )。考察  $Z = X + Y$ , 显然  $Z \geq 2$ 。计算  $P(Z = k)$ :

$$\begin{aligned}
 P(Z = k) &= \sum_{i=1}^{k-1} P(X = i)P(Y = k - i) \\
 &= \sum_{i=1}^{k-1} [(1-p)^{i-1}p] \cdot [(1-p)^{k-i-1}p] \\
 &= \sum_{i=1}^{k-1} p^2 (1-p)^{k-2} = (k-1)p^2 (1-p)^{k-2}
 \end{aligned}$$

由于  $P(Z = k)$  的表达式中出现了系数  $(k-1)$ , 这与几何分布的标准形式  $(1-p)^{k-1}p$  完全不同 (实际上它是负二项分布)。因此几何分布不具有可加性。

(2) 指数分布的反例(利用卷积公式):

设  $X, Y \sim E(\lambda)$  独立, 概率密度为  $f(x) = \lambda e^{-\lambda x}$  ( $x > 0$ )。求  $Z = X + Y$  的概率密度

$f_Z(z)$ 。当  $z > 0$  时, 利用卷积公式:

$$\begin{aligned}f_Z(z) &= \int_0^z f_X(x)f_Y(z-x)dx \\&= \int_0^z (\lambda e^{-\lambda x}) \cdot (\lambda e^{-\lambda(z-x)})dx \\&= \int_0^z \lambda^2 e^{-\lambda z} dx \\&= \lambda^2 e^{-\lambda z} \int_0^z 1 dx = \lambda^2 z e^{-\lambda z}\end{aligned}$$

所得密度函数  $f_Z(z) = \lambda^2 z e^{-\lambda z}$  (此为伽马分布), 其中多出了变量  $z$  作为乘子, 显然不再是指数分布的形式。因此指数分布不具有可加性。

## 2.2 随机变量的函数的分布

### 1. 一维随机变量的函数的分布

例题 2.4 求  $Y = e^{-X}$  的密度函数

已知连续型随机变量  $X$  具有密度函数:

$$f(x) = \begin{cases} 0.5e^{-x} + e^{-2x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

求随机变量  $Y = e^{-X}$  的密度函数  $f_Y(y)$ 。

解答 这里我们使用分布函数求导法。这种方法思路最清晰, 且利用复合函数求导可以免去求积分的麻烦。

第一步: 确定  $Y$  的取值范围

因为  $x > 0$ , 且  $Y = e^{-X}$  单调递减, 所以  $Y$  的取值范围是  $e^{-\infty} < Y < e^0$ , 即  $0 < y < 1$ 。

第二步: 利用分布函数转化并直接求导

当  $0 < y < 1$  时, 写出  $Y$  的分布函数  $F_Y(y)$ :

$$\begin{aligned}F_Y(y) &= P\{Y \leq y\} = P\{e^{-X} \leq y\} \\&= P\{-X \leq \ln y\} = P\{X \geq -\ln y\} \\&= 1 - P\{X < -\ln y\} = 1 - F_X(-\ln y)\end{aligned}$$

对两边关于  $y$  直接求导, 利用复合函数求导法则, 即可直接得到密度函数  $f_Y(y)$ :

$$\begin{aligned} f_Y(y) &= F'_Y(y) = \frac{d}{dy}[1 - F_X(-\ln y)] \\ &= -f_X(-\ln y) \cdot \frac{d}{dy}(-\ln y) \\ &= -f_X(-\ln y) \cdot \left(-\frac{1}{y}\right) \\ &= f_X(-\ln y) \cdot \frac{1}{y} \end{aligned}$$

第三步: 代入原密度函数计算

将  $x = -\ln y$  代入原分布的密度函数  $f(x) = 0.5e^{-x} + e^{-2x}$  中:

$$f_Y(y) = (0.5e^{-(-\ln y)} + e^{-2(-\ln y)}) \cdot \frac{1}{y}$$

利用对数恒等式  $e^{\ln y} = y$  以及  $e^{2\ln y} = y^2$ , 上式可进一步化简:

$$\begin{aligned} f_Y(y) &= (0.5y + y^2) \cdot \frac{1}{y} \\ &= 0.5 + y \end{aligned}$$

结论:

当  $y \notin (0, 1)$  时,  $f_Y(y) = 0$ 。因此,  $Y$  的密度函数为:

$$f_Y(y) = \begin{cases} y + 0.5, & 0 < y < 1 \\ 0, & \text{其他} \end{cases}$$

## 2. 两个随机变量的函数的分布

### 例题 2.5 求 $Z = XY$ 的密度函数

已知二维连续型随机变量  $(X, Y)$  的密度函数如下:

$$f(x, y) = \begin{cases} x, & 1 \leq x \leq 2, \frac{1}{x} \leq y \leq \frac{2}{x} \\ 0, & \text{其他} \end{cases}$$

求  $Z = XY$  的密度函数  $f_Z(z)$ 。

解答 根据两个随机变量的函数的分布定理, 设  $Z = g(X, Y) = XY$ 。  
由题意知, 在  $f(x, y) \neq 0$  的区域内  $1 \leq x \leq 2$ , 所以  $x \neq 0$ 。

解出反函数  $y = h(x, z) = \frac{z}{x}$ , 求偏导得到  $\frac{\partial h}{\partial z} = \frac{1}{x}$ 。

由于  $x > 0$ , 所以雅可比因子的绝对值为:

$$\left| \frac{\partial h}{\partial z} \right| = \frac{1}{x}$$

代入定理公式:

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, h(x, z)) \left| \frac{\partial h}{\partial z} \right| dx = \int_{-\infty}^{+\infty} f\left(x, \frac{z}{x}\right) \frac{1}{x} dx$$

确定非零区间的积分上下限(核心步骤):

被积函数  $f\left(x, \frac{z}{x}\right)$  不为零的条件是点  $\left(x, \frac{z}{x}\right)$  必须落在原密度函数的非零区域内。代入原条件得:

$$\begin{cases} 1 \leq x \leq 2 \\ \frac{1}{x} \leq \frac{z}{x} \leq \frac{2}{x} \end{cases}$$

因为  $x > 0$ , 我们将第二个不等式同时乘以  $x$ , 得到关于  $z$  的范围:

$$1 \leq z \leq 2$$

此时, 这组条件变为:  $1 \leq z \leq 2$  且  $1 \leq x \leq 2$ 。

这说明, 当  $z$  取  $[1, 2]$  中的任意值时,  $x$  的积分区间始终是整个  $[1, 2]$ , 并不受到  $z$  的耦合限制。

计算积分:

当  $1 \leq z \leq 2$  时, 代入原密度函数  $f(x, y) = x$  (此时  $y$  的位置被  $\frac{z}{x}$  替代, 但原函数表达式中并没有  $y$ , 所以直接就是  $x$ ):

$$\begin{aligned} f_Z(z) &= \int_1^2 x \cdot \frac{1}{x} dx \\ &= \int_1^2 1 dx \\ &= [x]_1^2 = 2 - 1 = 1 \end{aligned}$$

当  $z$  不在  $[1, 2]$  范围内时,  $f_Z(z) = 0$ 。

结论:

$Z = XY$  的密度函数为:

$$f_Z(z) = \begin{cases} 1, & 1 \leq z \leq 2 \\ 0, & \text{其他} \end{cases}$$

### 3. 二维分布函数与区域概率的直接积分

### 例题 2.6 求分布函数与区域概率

设二维随机变量  $(X, Y)$  具有概率密度

$$f(x, y) = \begin{cases} 2e^{-(2x+y)}, & x > 0, y > 0, \\ 0, & \text{其他.} \end{cases}$$

- (1) 求分布函数  $F(x, y)$ ;
- (2) 求概率  $P\{Y \leq X\}$ 。

解答

(1) 求分布函数  $F(x, y)$

根据二维分布函数的定义  $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du$ 。

当  $x \leq 0$  或  $y \leq 0$  时, 显然有  $F(x, y) = 0$ 。

当  $x > 0$  且  $y > 0$  时, 被积函数为  $f(u, v) = 2e^{-(2u+v)}$ :

$$\begin{aligned} F(x, y) &= \int_0^x \int_0^y 2e^{-(2u+v)} dv du \\ &= \left( \int_0^x 2e^{-2u} du \right) \cdot \left( \int_0^y e^{-v} dv \right) \\ &= [-e^{-2u}]_0^x \cdot [-e^{-v}]_0^y \\ &= (1 - e^{-2x})(1 - e^{-y}) \end{aligned}$$

因此, 联合分布函数为:

$$F(x, y) = \begin{cases} (1 - e^{-2x})(1 - e^{-y}), & x > 0, y > 0 \\ 0, & \text{其他} \end{cases}$$

(2) 求概率  $P\{Y \leq X\}$  (利用二重积分直接求解)

要求  $P\{Y \leq X\}$ , 我们不要求出  $Z = Y - X$  的分布, 而是直接将条件  $Y \leq X$  作为二重积分的积分区域  $D$ 。

由题意, 联合密度非零的区域是第一象限 ( $x > 0, y > 0$ ), 再结合条件  $y \leq x$ , 积分区域  $D$



可以表示为:  $0 < x < +\infty$  且  $0 < y < x$ 。

$$\begin{aligned} P\{Y \leq X\} &= \iint_{y \leq x} f(x, y) dx dy \\ &= \int_0^{+\infty} \left( \int_0^x 2e^{-(2x+y)} dy \right) dx \\ &= \int_0^{+\infty} 2e^{-2x} [-e^{-y}]_0^x dx \\ &= \int_0^{+\infty} 2e^{-2x} (1 - e^{-x}) dx \\ &= \int_0^{+\infty} (2e^{-2x} - 2e^{-3x}) dx \\ &= \left[ -e^{-2x} + \frac{2}{3}e^{-3x} \right]_0^{+\infty} \\ &= \lim_{x \rightarrow +\infty} \left( -e^{-2x} + \frac{2}{3}e^{-3x} \right) - \left( -e^0 + \frac{2}{3}e^0 \right) \\ &= 0 - \left( -1 + \frac{2}{3} \right) \\ &= \frac{1}{3} \end{aligned}$$

故  $P\{Y \leq X\} = \frac{1}{3}$ 。

## 2.3 边缘分布和条件分布

### 1. 二维随机变量的边缘与条件密度

#### 例题 2.7 求解常数、边缘密度与条件密度

已知二维随机变量  $(X, Y)$  的概率密度函数为

$$f(x, y) = \begin{cases} \frac{1}{A}, & -1 \leq x \leq 1, 0 \leq y \leq x^2 \\ 0, & \text{其他} \end{cases}$$

其中  $A$  为常数。

- (i) 试求常数  $A$ ;
- (ii) 求边缘概率密度  $f_Y(y)$ ;
- (iii) 求条件概率密度  $f_{X|Y}(x|y)$ 。

解答

- (i) 求常数  $A$

根据二维概率密度函数的归一性性质, 联合密度在整个平面的二重积分必须等于 1, 即  $\iint_{-\infty}^{+\infty} f(x, y) dx dy = 1$ 。

积分区域  $D$  为  $-1 \leq x \leq 1, 0 \leq y \leq x^2$ 。我们选择先对  $y$  积分, 后对  $x$  积分:

$$\begin{aligned}\iint_D \frac{1}{A} dx dy &= \frac{1}{A} \int_{-1}^1 \left( \int_0^{x^2} dy \right) dx \\ &= \frac{1}{A} \int_{-1}^1 x^2 dx \\ &= \frac{1}{A} \left[ \frac{1}{3} x^3 \right]_{-1}^1 \\ &= \frac{1}{A} \left( \frac{1}{3} - \left( -\frac{1}{3} \right) \right) = \frac{2}{3A}\end{aligned}$$

令  $\frac{2}{3A} = 1$ , 解得  $A = \frac{2}{3}$ 。

因此, 联合概率密度函数为:

$$f(x, y) = \begin{cases} \frac{3}{2}, & -1 \leq x \leq 1, 0 \leq y \leq x^2 \\ 0, & \text{其他} \end{cases}$$

(ii) 求边缘概率密度  $f_Y(y)$

由联合密度的非零区域  $0 \leq y \leq x^2 \leq 1$  可知,  $Y$  的可能取值范围是  $0 < y < 1$ 。

对于固定的  $y \in (0, 1)$ , 要求原密度函数非零, 对应的  $x$  必须满足  $x^2 \geq y$  且  $-1 \leq x \leq 1$ 。

解这个不等式, 得到  $x$  的范围是由两段区间组成的:  $x \in [-1, -\sqrt{y}] \cup [\sqrt{y}, 1]$ 。

因此, 对  $x$  积分时需要分段:

$$\begin{aligned}f_Y(y) &= \int_{-\infty}^{+\infty} f(x, y) dx \\ &= \int_{-1}^{-\sqrt{y}} \frac{3}{2} dx + \int_{\sqrt{y}}^1 \frac{3}{2} dx \\ &= \frac{3}{2}(-\sqrt{y} - (-1)) + \frac{3}{2}(1 - \sqrt{y}) \\ &= \frac{3}{2}(1 - \sqrt{y}) + \frac{3}{2}(1 - \sqrt{y}) \\ &= 3(1 - \sqrt{y})\end{aligned}$$

当  $y$  不在  $(0, 1)$  范围内时,  $f_Y(y) = 0$ 。所以边缘概率密度为:

$$f_Y(y) = \begin{cases} 3(1 - \sqrt{y}), & 0 < y < 1 \\ 0, & \text{其他} \end{cases}$$

(iii) 求条件概率密度  $f_{X|Y}(x|y)$

根据条件概率密度的定义:  $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$  (当  $f_Y(y) > 0$  时)。

对于给定的  $0 < y < 1$ , 有  $f_Y(y) = 3(1 - \sqrt{y})$ 。将  $f(x, y)$  和  $f_Y(y)$  直接代入公式:

$$f_{X|Y}(x|y) = \frac{3/2}{3(1 - \sqrt{y})} = \frac{1}{2(1 - \sqrt{y})}$$

注意, 此条件密度有效的  $x$  范围即为原联合密度非零的区域(因为给定  $y$  的前提下,  $x$  只能在特定的范围内取值), 即  $x \in [-1, -\sqrt{y}] \cup [\sqrt{y}, 1]$ 。

因此, 条件概率密度为:

$$f_{X|Y}(x|y) = \begin{cases} \frac{1}{2(1-\sqrt{y})}, & x \in [-1, -\sqrt{y}] \cup [\sqrt{y}, 1] \\ 0, & \text{其他} \end{cases}$$

## 2.4 最大值、最小值分布

### 1. 二维均匀分布的几何概型解法

#### 例题 2.8 雷达屏幕上的均匀分布

雷达的圆形屏幕半径为  $R$ , 设目标出现点  $(X, Y)$  在屏幕上服从均匀分布。

- (1) 求  $P\{Y > 0 \mid Y > X\}$ ;
- (2) 设  $M = \max\{X, Y\}$ , 求  $P\{M > 0\}$ 。

解答

因为点  $(X, Y)$  在半径为  $R$  的圆  $D: x^2 + y^2 \leq R^2$  上服从均匀分布, 所以这是一个典型的几何概型问题。对于圆内的任意区域  $G$ , 点落在  $G$  内的概率等于  $G$  的面积与圆面积的比值, 即  $P((X, Y) \in G) = \frac{S_G}{\pi R^2}$ 。

(1) 求  $P\{Y > 0 \mid Y > X\}$

根据条件概率公式:

$$P\{Y > 0 \mid Y > X\} = \frac{P\{Y > 0, Y > X\}}{P\{Y > X\}}$$

首先计算分母  $P\{Y > X\}$ :

区域  $Y > X$  是直线  $y = x$  上方的半圆。根据对称性, 其面积正好是整个圆面积的一半, 因此:

$$P\{Y > X\} = \frac{1}{2}$$

接着计算分子  $P\{Y > 0, Y > X\}$ :

该事件要求点同时满足  $y > 0$  (在  $x$  轴上方) 和  $y > x$  (在直线  $y = x$  上方)。

在极坐标系下,  $y > 0$  对应角度  $\theta \in (0, \pi)$ ,  $y > x$  对应角度  $\theta \in (\frac{\pi}{4}, \frac{5\pi}{4})$ 。

两者的交集为  $\theta \in (\frac{\pi}{4}, \pi)$ 。这个扇形的圆心角为  $\pi - \frac{\pi}{4} = \frac{3\pi}{4}$ ，占整个圆周角  $2\pi$  的  $\frac{3}{8}$ 。因此：

$$P\{Y > 0, Y > X\} = \frac{3}{8}$$

代入条件概率公式：

$$P\{Y > 0 \mid Y > X\} = \frac{3/8}{1/2} = \frac{3}{4}$$

(2) 求  $P\{M > 0\}$

已知  $M = \max\{X, Y\}$ 。直接求  $M > 0$  比较复杂，我们可以利用对立事件来转化：

$$P\{M > 0\} = 1 - P\{M \leq 0\}$$

而最大值小于等于 0，意味着两个变量同时小于等于 0：

$$P\{M \leq 0\} = P\{\max\{X, Y\} \leq 0\} = P\{X \leq 0, Y \leq 0\}$$

区域  $X \leq 0, Y \leq 0$  正好是圆在第三象限的部分。显然，它的面积是整个圆面积的  $\frac{1}{4}$ 。因此：

$$P\{X \leq 0, Y \leq 0\} = \frac{1}{4}$$

所以：

$$P\{M > 0\} = 1 - \frac{1}{4} = \frac{3}{4}$$